

Risco de crédito: identificar sinais de inadimplência

O que os dados revelam, o que o modelo consegue identificar
e o que ainda precisa melhorar antes do uso pelo banco



Elisangela Freitas do
Nascimento
RM377763



Lilian Fonseca Oliveira
RM377750



Marcel e Silva de
Almeida
RM377751



Michelle Ventura
Oliveira Costa
RM377779

1. A decisão começa pela qualidade do sinal

O projeto combina cadastro do solicitante e histórico mensal de crédito para investigar sinais associados a atrasos.

438 mil

registros cadastrais na base original

~46 mil

clientes com histórico de crédito na base de origem

36.457

registros após cruzamento para modelagem

11,8%

classificados como maus pagadores na base final

Como definimos “mau pagador”

Cliente com pelo menos um registro de status 1 a 5 — atraso de 30 dias ou mais na codificação usual da base. Atrasos de 1 a 29 dias (status 0) ficam fora da definição.

Por que isso importa


A regra torna o alvo claro e reproduzível, mas é uma escolha metodológica: uma ocorrência isolada já classifica o cliente como risco. Uma definição mais rígida pode gerar outro perfil de casos e outros resultados.

Mensagem-chave: antes de avaliar o modelo, é preciso saber exatamente qual comportamento ele foi treinado para reconhecer.

2. Quem está na base? O perfil ajuda a contextualizar o risco

A análise exploratória comparou idade, renda, ocupação, escolaridade e tipo de renda entre as classes.

Variáveis que ajudam a descrever os clientes



O que os dados permitem dizer

O projeto explora diferenças de distribuição por idade e renda, e compara a proporção de maus pagadores por tipo de renda. Essas diferenças são associações observadas, não prova de causa.


Na análise de contribuição ao modelo, destacam-se composição familiar, posse de automóvel, idade e posse de imóvel. A contribuição é pequena e o desempenho global do modelo continua limitado.

Cuidado de negócio: não usar características individuais isoladamente como justificativa automática para negar crédito.

3. Qual modelo encontra mais clientes de risco?

A comparação considera a capacidade de localizar maus pagadores — não apenas o percentual total de acertos.

Maus pagadores identificados no teste



Tradução para o negócio

Em cada 100 maus pagadores reais no conjunto de teste, a Regressão Logística identificou cerca de 42. O Extra Trees identificou cerca de 10 e o Random Forest, cerca de 4.

42 em 100

identificados pela Regressão Logística


58 em 100

não identificados por ela

Escolha preliminar: Regressão Logística, por recuperar mais casos de risco no limiar testado — não por estar pronta para decidir crédito.

4. O ganho tem um custo: muitos bons clientes também são sinalizados

Na amostra de teste, a Regressão Logística identificou mais casos de risco, mas gerou muitos alertas incorretos.



O principal alerta

Dos casos previstos como maus pagadores pela Regressão Logística, apenas cerca de 11,8% eram de fato da classe de risco.

Isso significa muitos falsos alertas: negar ou encarecer crédito a bons clientes teria custo comercial e de experiência.

Não há dados de valores financeiros no notebook para estimar prejuízo evitado em reais.

5. Recomendação à diretoria: não colocar em produção ainda

Os resultados indicam uma prova de conceito, não uma ferramenta pronta para aprovar ou negar crédito.

0,512

capacidade de distinção (ROC-AUC) da Regressão Logística; 0,5 é referência próxima ao acaso

0,126

precisão média; perto da prevalência de maus pagadores (~11,9%)

42%

dos maus pagadores identificados no teste

11,8%

de acerto entre os clientes sinalizados como risco

Próximas decisões recomendadas

1. Testar definições alternativas de mau pagador.
2. Ajustar o ponto de corte conforme o custo de cada erro.
3. Validar em dados novos e medir estabilidade.
4. Quantificar impacto financeiro e experiência do cliente.

Decisão proposta

Prosseguir com investigação e melhoria; não automatizar decisões de crédito com o desempenho atual. A Regressão Logística é a melhor candidata entre as três testadas para recuperar casos de risco, mas ainda não distingue bem as duas classes.

Mensagem final: identificar mais riscos é importante — mas só cria valor quando o sinal é confiável e os custos dos erros são conhecidos.

Obrigado!

Estamos à disposição.

Este projeto mostra o potencial dos dados para apoiar decisões de crédito mais seguras e sustentáveis.

Seguimos recomendando a continuidade do trabalho, com foco em aprimorar o modelo e validar seu impacto no negócio.



Mais confiança

Modelos mais precisos e estáveis.



Menos risco

Identificação mais eficiente de clientes com maior probabilidade de inadimplência.



Mais valor

Decisões de crédito que equilibram risco, crescimento e experiência do cliente.



Próximos passos

Aprofundar a análise, testar novos cenários e medir o impacto financeiro dos alertas para apoiar uma futura implementação.

